

## "بسمه تعالی"

### گزارش تمرین عملی دوم یادگیری ماشین - زهرا لطیفی - ۹۹۲۳۰۶۹

#### سوال اول

ابتدا کتابخانه نامپای ایمپورت شده. سپس دو آرایه  $9 \times 9$  ورودی را همانطور که در صورت سوال خواسته شده بود تعریف کردیم و L و H را ساختیم. به عنوان خروجی هم، برداری تعریف کردیم که دو کلاس 0 برای L و 1 برای H دارد. پس از این بخش، تابع فعالسازی سخت تک قطبی را تحت عنوان  $\text{step}(x)$  تعریف کردیم که به ازای مقادیر منفی خروجی 0 و به ازای سایر مقادیر خروجی 1 را بر می گرداند.

سپس وزن ها را با توزیع نرمال مقداردهی اولیه می کنیم و بایاس را برابر ۱- تعریف می کنیم. حال تابع  $\text{train}$  تعریف شده که در هر مرحله، بایاس، وزن ها و خطا را به عنوان ورودی گرفته، با روابط موجود در جزوه برای پرسپترون تک لایه، این سه ورودی را اصلاح کرده و به عنوان خروجی بر می گرداند.

برای شروع،  $\text{error} = 0$  را تعریف کرده و یک بار تابع  $\text{train}$  را فراخوانی کردیم. سپس تا هنگامی که  $\text{error} = 0$  نشده، آموزش بر روی تمام داده های ورودی را داخل حلقه  $\text{while}$  تکرار می کنیم تا شبکه آموزش داده شود.

نهایتاً از همان ورودی های آموزش استفاده کردیم تا شبکه را امتحان کنیم. شاهدیم که با ضریب یادگیری 0.01 توانستیم در ۶۰ اپیاک، خروجی کاملاً درستی در هر بار ران بگیریم.

```
Input: [0 1 1 0 1 1 0 0 0]
Predicted label: L
60
Input: [0 1 0 0 0 0 0 1 0]
Predicted label: H
60
```

یک بار هم داده ها را کمی نویزی کردیم:

```
test = np.array([[0, 1, 0,
                  0, 1, 1,
                  0, 0, 0], # noisy L
                 [0, 1, 0,
                  1, 0, 1,
                  0, 1, 0]]) # noisy H
```

این بار هم خروجی به درستی دسته بندی را انجام داد اما این بار در برخی ران ها پاسخ اشتباه می گیریم که علت آن بسیار محدود بودن دادگان آموزش است.

```
Input: [0 1 0 0 1 1 0 0 0]
Predicted label: L
Input: [0 1 0 1 0 1 0 1 0]
Predicted label: H
```

## سوال دوم

در این فاز کتابخانه‌های پانداس، نامپای، matplotlib، seaborn، sklearn، tensorflow و keras ایمپورت شده‌اند. داده‌ها بارگذاری شده و اطلاعات این مجموعه داده با دستور `dataset.info` و `dataset.describe()` بدست آمدند. پس از آن برای اینکه دید بهتری نسبت به داده‌ها داشته باشیم، `correlation` بین فیچرهای مختلف را رسم کرده‌ایم:



می‌دانیم که داده‌های ما، برچسب‌هایی از نوع `string` دارند؛ پس با استفاده از `OneHotEncoder()` برچسب‌ها را برای تمام داده‌ها `encode` می‌کنیم تا داشته باشیم:

```
Original labels: ['Dropout' 'Enrolled' 'Graduate']
One-hot encoded labels:
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]
```

از آنجایی که مقادیر ویژگی‌های مختلف بازه‌های بسیار متفاوتی داشتند، باید `normalization` روی آن‌ها انجام می‌گرفت پس با کد زیر این کار را با روش `Mean-Std` یعنی کم کردن میانگین هر ییتون از هر داده و تقسیم کردن بر انحراف معیار داده‌های آن ستون انجام دادیم:

```
#apply normalization techniques (mean/std)
for column in x_train :
    x_train[column] = (x_train[column] - x_train[column].mean()) /
x_train[column].std()
```

به تعریف مدل می‌رسیم. لایه ورودی ابعادی برابر با ابعاد ورودی (۳۶ فیچر) دارد، لایه بعدی یک لایه پنهان با ۶۴ نورون است که تابع فعالساز *Relu* دارد. این تابع مشتقی برابر یک در بخش مثبت دارد که کار را راحت‌تر می‌کند و همینطور *sparse* بیشتری مثلاً نسبت به *tanh* دارد که به این معناست که از *Overfitting* جلوگیری می‌کند. پس از این لایه از یک لایه *DropOut* استفاده کردیم تا باز هم از *Overfitting* جلوگیری شود. سپس یک لایه پنهان با ۳۲ نورون قرار داده و برای افزایش سرعت آموزش، یک لایه *BatchNormalization* اضافه کردیم. نهایتاً یک لایه با ۱۶ نورون دیگر اضافه کردیم تا مدل عمیق‌تر شود. با توجه به اینکه ۳ کلاس در خروجی داریم، لایه خروجی *softmax* با اندازه ۳ خواهد داشت. خلاصه مدل به شکل زیر گزارش شده است:

```
Model: "sequential_17"
Layer (type)                Output Shape                Param #
=====
dense_75 (Dense)             (None, 64)                  2368
dropout_18 (Dropout)         (None, 64)                  0
dense_76 (Dense)             (None, 32)                  2080
batch_normalization_20 (Bat  (None, 32)                  128
chNormalization)
dense_77 (Dense)             (None, 16)                  528
dense_78 (Dense)             (None, 3)                   51
=====
Total params: 5,155
Trainable params: 5,091
Non-trainable params: 64
```

مدل را *compile* کردیم. در این مرحله از *optimizer* آدام استفاده کردیم اما در روند آموزش ترجیح دادیم ضریب یادگیری را به صورت *manual* به ۰.۰۰۰۵ کاهش دهیم. مدل را به داده‌های *train*، در ۱۰۰ اپیاک فیت کردیم. در این مرحله هر بار ۱۰ درصد داده‌ها برای *validation* کنار گذاشته می‌شود و از *earlyStopping* استفاده کردیم تا دچار *Overfitting* نشویم. در ۵۸ اپیاک به دقت ۷۹ درصد بر روی داده‌های آموزش و ۷۴ درصد بر روی داده‌های *valid* رسیدیم.

```
Epoch 58/100
14/14 [=====] - 0s 5ms/step - loss: 0.5141 - accuracy: 0.7941 -
val_loss: 0.6133 - val_accuracy: 0.7430
Epoch 58: early stopping
```

نمودارهای دقت و  $loss$  هم رسم شده اند که به شرح زیر هستند:

